

# 无监督学习

## KMeans

☐ 过一遍KMeans的流程

基于质心

sensitive to outliers

- 特别大的值会大幅扰乱数据分布

改进: K-medoids

k-medoids 每次选取的质心, 必须是样本点,  
而 k-means每次选取的质心可以是样本点之外的点

K-Medoids 的重点, 就在于中心点的选取。

选取簇中心点的准则函数是: **当前簇中所有其他点到该中心点的距离之和最小**  
需要遍历簇中所有点

## PCA

皮尔逊相关系数: 刻画变量之间线性相关程度

$$\text{corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_x \sigma_y}$$

性质:

- 绝对值不大于1
- 绝对值=1的充要条件是存在常数a和b, 使得 $Y=aX+b$
- 皮尔逊相关系数是对称的
- 取值越大, 二者在线性相关的意义下相关程度越大

将d维特征数据映射到l维空间, 将原始数据向这些数据方差最大的方向进行投影, 一旦发现方差最大的投影方向, 则继续寻找保持方差第二的方向且进行投影 (保证方向的正交性)

- 最优化的方差等于原始样本数据X的协方差矩阵 $\Sigma$ 的特征根之和
- 要使方差最大, 求协方差矩阵 $\Sigma$ 的特征向量和特征根, 然后取前l个最大特征根所对应的特征向量组成映射矩阵W

算法步骤:

1. 对每个样本数据 $x_i$ 进行中心化处理
2. 计算原始样本数据的协方差矩阵:  $\Sigma = \frac{1}{n-1} X^T X$
3. 对协方差矩阵 $\Sigma$ 进行特征值分解, 对所得特征根按其值大到小排序 $\lambda_1 \geq \lambda_2 \geq \dots \lambda_d$
4. 取前l个最大特征根所对应特征向量 $w_1, w_2, \dots, w_l$ 组成映射矩阵W

5. 将每个样本数据 $x_i$ 按照如下方法降维:  $x_i(1 \times d) \rightarrow W(d \times l) \rightarrow 1 \times l$

□ PCA流程

线性区别分析(LDA)

类内散度矩阵: K个类, 每个类中的样本-均值之和

类间散度矩阵

## 非负矩阵分解(NMF)

$D = WH$  将D分解成非负的 $W, H$

利用任意一个可逆矩阵A以及他的逆矩阵 $A^{-1}$ , 可得 $WH = WAA^{-1}H$ 。很容易找到A使得 $\hat{W} = WA$ 和 $\hat{H} = A^{-1}H$ 均非负。这样就找到另一种分解,  $D = \hat{W}\hat{H}$

两种代价函数:

- 欧氏距离平方函数

$$\|D - WH\|_F^2 = \sum_{0 \leq i < n, 0 \leq j < d} (D_{i,j} - (WH)_{i,j})^2$$

- KL散度函数

$$D_{KL}(D||WH) = \sum_{0 \leq i < n, 0 \leq j < d} D_{i,j} \log \frac{D_{i,j}}{(WH)_{i,j}} - D_{i,j} + (WH)_{i,j}$$

对应的两种迭代方式

书p168

策略:

对于欧氏距离平方函数, 保证分子分母的形状和目标矩阵相同, 分子有D, 分母无D

对于KL散度的那种迭代, 感觉不太对

## 多维尺度法(MDS)

保持原始数据之间两两距离不变, **无法对新数据集进行降维**

方法:

1. 计算距离矩阵A
2.  $H = I - \frac{1}{n} l_n l_n^T$
3.  $B = -\frac{1}{2} H A H$
4.  $B = \Gamma \Lambda \Gamma^T$
5. 其中只取前l个非零特征根, 前面的是 $n \times l$ 矩阵, 每一列都是特征根对应的特征向量

于是 $X = [x_1, \dots, x_i, \dots, x_n]$ 中 $d$ 维原始数据可通过如下变换转变为 $l$ 维数据，从

而实现降维：

6.

$$\bar{X}^T = [\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n]^T = \Gamma \Lambda^{1/2}$$

其中 $\bar{x}_i (1 \leq i \leq n)$ 表示原始数据 $x_i$ 降维后的结果。

## 局部线性嵌入 (LLE)

LLE假设数据在较小的局部是线性的：某一个数据可以由它邻域中的几个样本来线性表示。

线性关系只在样本的附近起作用（所以用了K近邻）

ppt中的 $x$ 是原始数据， $y$ 是其到低维的投影，我们希望其仍能够保持线性关系，也就是先前在 $x$ 上应用的 $w$ 权重我们希望仍能应用到 $y$ 上，即对 $y$ 的均方差损失函数最小，因此二者损失函数有着一样的形式

区别是高维的式子中，高维数据已知，目标是求最小值对应的权重系数 $W$ ，而我们在低维是权重系数 $W$ 已知，求对应的低维数据。注意，这里的 $W$ 已经是 $m \times m$ 维度，之前的 $W$ 是 $m \times k$ 维度，我们将那些不在邻域位置的 $W$ 的位置取值为0，将 $W$ 扩充到 $m \times m$ 度。

ppt(4)中的对降维结果增加一定约束，是指让 $y$ 标准化

$$M = (I - W)^T(I - W), \text{ 使用拉格朗日乘子, 可得 } MY^T = \lambda Y^T$$

最终通过拉格朗日乘子法，取矩阵 $M$ 最小的前 $k$ 个非零特征根所对应向量构成的矩阵

<https://www.cnblogs.com/pinard/p/6266408.html>

## 特征人脸方法

基于PCA

$$Y(n \times l) = X(n \times d) * W(d \times l)$$

$X$ 的协方差矩阵，求取前 $l$ 个特征值，并用特征向量组成 $W$

$x * w$  获取到降维的人脸  $d \rightarrow l$

$w(d \times l)$  可以变成 $l$ 个特征人脸

降维后的人脸是指 $Y$ ，人脸数目不变，但是维数变少

特征人脸实际上是 $W$ ， $L$ 个人脸图片  $\Rightarrow L$ 个特征人脸

相关系数的获得：每个原来的人脸图片都与每个特征人脸（ $W$ 的一维）做矩阵乘法得到一个相关系数

$$(1 \times d) \times (d \times l) = (1 \times l) \text{ 总共获得 } l \text{ 个相关系数}$$

在后续人脸识别分类中，计算两张人脸是否类似，是看各自的这 $l$ 个相关系数是否相似

6.16:

$l$ 个相关系数的取得：每个原来的人脸图片都与 $W(d \times l)$ 相乘，获得 $(1 \times l)$ 的向量，每个值就是一个相关系数

$l$ 个相关系数指的是 $l$ 维向量，相比原始的 $d$ 其数目会大减，达成了降维的效果

## 奇异值分解 (svd)

核心就是求取左右的矩阵 $U$ 和 $V$ ，该过程可以通过 $A^T A V = \lambda V$ 的形式来求

$$A A^T = \lambda U \text{ 求 } U$$

$U$ 和 $V$ 乘自身转置都是单位阵

奇异值的获取：任一种特征值开根号，特征值组成的矩阵是 $\sum^T \sum$ ，但是只有对角线上有元素，对应的就是奇异值的平方

6.16:

非负奇异值的个数： $\min(m, n)$

过程是从 $A$ 出发，但因为 $A$ 不是方阵，所以要写成 $A^T A$ 和 $A A^T$ 的方阵形式，分别求出右奇异矩阵 $V$ 和左奇异矩阵 $U$ ，这二者分别代表右奇异向量和左奇异向量的合并。其对应的特征值能拼成一个矩阵，矩阵对角线为所有特征值，该矩阵即是 $\sum \sum^T$ 或 $\sum^T \sum$ ，奇异值便是特征值开根号

□ 奇异值分解实现特征人脸

## 潜在语义分析

1. 计算单词——文档矩阵
2. 奇异值分解/非负矩阵分解
3. 重建矩阵
4. 挖掘语义关系

计算任意两个文档之间的皮尔逊相关系数，得到文档——文档相关系数矩阵

## 期望最大化算法

- 最大似然估计
- 最大后验估计：与最大似然估计相比，增加了一项与 $\theta$ 相关的先验概率 $P(\theta)$ 。

无论上面哪种做法，都是充分利用已有数据，在参数模型确定（只是参数值未知）情况下，对所优化目标中的参数求导，令导数为0，求取模型的参数值

隐变量

计算隐变量（EM算法的E步），最大化似然函数和更新模型参数（EM算法的M步）

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})}{q(\mathbf{Z})} \right\} \\ \text{KL}(q \| p) &= - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta})}{q(\mathbf{Z})} \right\}\end{aligned}$$

□ 自监督学习